

LLM Context Compaction Proxy

技术文档

永不限, 永不停歇 · Never Full, Never Stop

LLM Context Compaction Proxy Contributors

2026 年 8 月

目录

1 概述	4
1.1 工作原理	4
1.2 环境要求	4
2 架构设计	4
2.1 请求流程	4
2.2 模块划分	5
3 压缩技术栈	5
3.1 V3 核心技术 (8 项)	5
3.2 V4 增强技术 (10 项)	6
4 核心算法解析	7
4.1 CJK 感知的 Token 估算	7
4.2 ARC 地址化引用 (Addressable Recall Compaction)	7
4.3 PACMS 子模选择	7
4.4 压缩安全验证	8
5 压缩流水线详解	8
5.1 do_compaction 主流程	8
5.2 增量压缩	9
5.3 双层压缩 (Dual-Layer)	9
6 协议转换层	10
6.1 OpenAI → Anthropic 请求转换	10
6.2 Anthropic → OpenAI 响应转换	10
6.3 自动 Provider 探测	10

7 可靠性组件状态机	10
7.1 熔断器 (CircuitBreaker)	10
7.2 抖动检测 (ThrashingDetector)	11
7.3 压缩缓存 (CompactionCache)	11
7.4 格式回退与重试	11
8 会话存储架构	11
8.1 SessionStore(SQLite + FTS5)	11
8.2 SemanticMemory(情节—语义双层记忆)	12
8.3 UserProfile(用户画像)	12
9 配置说明	12
9.1 核心配置	12
9.2 压缩行为	12
9.3 双引擎压缩	13
9.4 安全	13
9.5 会话与记忆	13
10 接入指南	13
10.1 DeepSeek	13
10.2 DeepSeek Harness	14
10.3 Hermes Agent	14
10.4 Claude Code	15
10.5 OpenClaw	15
11 原有上下文系统屏蔽	16
11.1 屏蔽原则	16
11.2 OpenClaw	16
11.3 Hermes Agent	17
11.4 DeepSeek Harness	17
11.5 Claude Code	17
11.6 屏蔽效果验证	18
12 安全与可靠性	18
12.1 认证	18
12.2 密钥保护	18
12.3 并发安全	18
12.4 可靠性组件	19
13 验证结果	19

14 常见问题	19
14.1 401 Unauthorized	19
14.2 上下文未压缩	19
14.3 格式错误	19

1 概述

LLM Context Compaction Proxy 是一个部署在 AI Agent 与 LLM API 之间的透明上下文压缩代理。当对话上下文逼近模型上下文窗口上限时, 它自动压缩历史消息并重试, 使 Agent 能够长时间运行而不触碰上下文窗口墙。

代理累计实现 **33 项压缩技术**, 横跨 7 代演进 (V3 核心、V4 增强、V5 会话、V6 Provider、V7 MemSkill), 技术来源涵盖学术论文 (ARC、AFM、PACMS、CoMem、MemSkill) 与生产实践 (Cursor、Devin、SWE-agent、Hermes、Claude Code)。

1.1 工作原理

AI Agent	Compaction Proxy	LLM Provider
(Claude/GPT)	localhost:8198	(any API)

- Monitor context %
- Auto-compress
- Preserve key info
- Route to provider

1. **透传 (Passthrough)**——上下文未达阈值时请求零开销直达上游;
2. **检测 (Detect)**——上下文达到阈值 (默认 80%) 时触发压缩;
3. **压缩 (Compress)**——使用独立的压缩模型对旧消息生成摘要;
4. **恢复 (Resume)**——压缩结果替换旧消息, Agent 无缝继续。

1.2 环境要求

- Python 3.10+
- aiohttp (pip install aiohttp)
- 上游 LLM API (OpenAI / Anthropic / Gemini / DeepSeek / Ollama 等)

2 架构设计

2.1 请求流程

Request Flow:

Agent → Proxy → [context check] → Upstream

if > 80% full:

Compact Compaction Model (separate provider)
Engine Compressed Summary

Replace old messages
with compressed summary

→ Upstream (with compacted context)

2.2 模块划分

- **Provider 抽象层**: OpenAI / Anthropic / Gemini 三大 API 格式的统一适配, 自动探测请求来源与上游格式;
- **压缩引擎**: 可插拔架构, 内置默认引擎与双引擎 (Dual-Layer);
- **记忆系统**: 语义记忆 (SemanticMemory)、跨会话存储 (SessionStore, SQLite+FTS5)、用户画像 (UserProfile);
- **技能系统 (V7)**: 技能注册表 (SkillRegistry)、技能控制器 (SkillController)、自演进记忆技能 (MemSkill);
- **可靠性组件**: 熔断器 (CircuitBreaker)、抖动检测 (ThrashingDetector)、压缩缓存 (CompactionCache)、指标系统 (Metrics)。

3 压缩技术栈

3.1 V3 核心技术 (8 项)

#	技术	说明
1	ARC 地址化引用	以紧凑的 @ref 指针替换重复内容
2	AFM 自适应保真	消息级 Full/Compressed/Placeholder 三级保真
3	PACMS 子模选择	贪心、保真感知的消息选择
4	CCL 承诺提取	提取并保留对话中的承诺
5	抖动检测	检测压缩循环 (3 次/5 条消息)
6	两阶段 Token 估算	CJK 感知的精确计数
7	预飞安全验证	发送前验证上下文合法性
8	并行压缩	大上下文分块并行压缩

3.2 V4 增强技术 (10 项)

#	技术	来源
9	情节—语义双层记忆	arXiv:2605.17625
10	思考掩码	Kevin-32B / Devin 模式
11	标签选择性保留	SWE-agent / memor-ai
12	结构感知工具输出压缩	memor-ai
13	密钥脱敏	Cursor / memor-ai
14	缓存优化消息排序	层哈希感知 + <code>cache_control</code> 断点
15	增量压缩	CoMem (arXiv:2605.30842)
16	四信号记忆评分	语义 50%、近因 25%、类型 15%、质量 10%
17	查询位置优化	查询置尾、配对邻接、近期窗口
18	压缩项剪枝	OpenAI 模式

4 核心算法解析

本节深入剖析代理内部的核心算法实现, 所有内容均对应源码 (compaction-proxy.py) 中的实际逻辑。

4.1 CJK 感知的 Token 估算

源码 estimate_tokens_v3 对文本按字符类型分类计数, 并依据每类字符的 token 密度折算:

$$T(\text{text}) = \frac{N_{\text{CJK}}}{1.5} + \frac{N_{\text{ASCII}}}{4.0} + \frac{N_{\text{other}}}{2.5} \quad (1)$$

- N_{CJK} : 中日韩统一表意文字数 (约 1.5 字符/token);
- N_{ASCII} : ASCII 字符数 (约 4 字符/token);
- N_{other} : 其余 Unicode 字符 (约 2.5 字符/token)。

估算结果取整且最小为 1。代理采用**两阶段**策略: 快速启发式 (estimate_tokens_fast) 用于预筛, 精确逐消息估算 (estimate_messages_tokens) 用于预算决策。

4.2 ARC 地址化引用 (Addressable Recall Compaction)

源码 apply_arc_citations 将**超过 800 字符**的 tool_result 替换为短 ID 引用, 原文存入 ARCLog:

```
if len(result_text) > 800:
    arc_id = arc_log.store(result_text, source_msg_idx=i)
    citation = arc_log.make_citation(arc_id, preview_len=100)
    new_block["content"] = (
        "[ARC Reference: {citation}]\n"
        "Full content available via ID: {arc_id}"
    )
```

- 阈值:800 字符 (低于阈值的内容原样保留, 避免过度引用);
- 存储:ARCLog 内存环 (默认上限 500 条), 支持按 ID 回查 (HTTP GET /arc/{arc_id});
- 引用形式:[ARC Reference: < 前 100 字符 >] + 完整 ID, LLM 在需要细节时可经回查端点取回原文。

4.3 PACMS 子模选择

源码 submodular_select 以**贪心近似**求解带预算的子模最大化 (论文 arXiv:2606.20047 的四信号记忆评分体系):

1. **评分**: 对每条消息计算重要性 I_i (`_message_importance_v4`: 语义 50%、近因 25%、类型 15%、质量 10%);
2. **保真加权**: 按 AFM 保真级别调整——FULL 乘 1.5, PLACEHOLDER 乘 0.5(可由 MemSkill 覆盖);
3. **成本**: 每条消息的 token 估算 C_i (至少为 1);
4. **贪心选择**: 在预算内反复选取 $\arg \max_i (I_i/C_i)$, 直至预算耗尽或无可选消息。

系统性约束: role 为 system 的消息**必须选中**, 不参与贪心竞争, 保证系统提示完整保留。

4.4 压缩安全验证

源码 `verify_compaction_safety` 在压缩后执行**预飞安全校验** (arXiv:2606.03618 safety pattern):

$$\text{safe} \iff T(\text{compacted}) < T(\text{original}) \quad (2)$$

若压缩结果 token 数**不小于**原文, 判定为不安全, 降级为 `aggressive_truncate_messages` 激进截断, 防止压缩反而膨胀。

5 压缩流水线详解

5.1 do_compaction 主流程

源码 `do_compaction` 是压缩的核心入口, 按以下顺序执行:

1. **MemSkill 技能选择** (V7): 构建 `CompactionContext`, 由 `SkillController` 按关键词匹配 + Gumbel-Top-K 选择技能;
2. **抖动检测**: 若 `ThrashingDetector` 判定蠕变 (窗口内压缩次数达到阈值), 直接切换激进截断并返回;
3. **预压缩 Hook**: 调用 `HookManager.call_pre_compact`, 可阻断本次压缩;
4. **自适应 keep_turns**: 按用户消息数动态下调保留轮次, 确保存在可压缩的旧消息;
5. **消息拆分**: `split_messages` 分为旧消息与近期消息;
6. **语义记忆提取**: 可选 LLM 驱动记忆提取 + 正则兜底, 知识写入 `SemanticMemory`;
7. **ARC 引用替换**: 长 `tool_result` 转 ID 引用;
8. **AFM 保真分级**: 为每条消息标注 Full/Compressed/Placeholder;
9. **CCL 承诺提取**: 抽取目标/约束/决策/错误/文件操作;
10. **子模选择**: 在预算内选择最重要的旧消息;

11. **并行块压缩**: 选中消息 ≥ 6 条时 `compact_messages_parallel` 分块并行摘要;
12. **后压缩 Hook**: 允许 webhook 修改摘要;
13. **构建压缩消息**: 摘要 + 近期消息重组;
14. **孤儿工具对清理**: `sanitize_tool_pairs`;
15. **会话持久化**: `SessionStore` 保存会话与原始转录;
16. **安全验证 + 重试**: 验证失败降级截断; 非预压缩场景还向上游发一次验证请求确认不再溢出。


5.2 增量压缩

`compact_messages` 支持**增量压缩** (CoMem, arXiv:2605.30842): 若存在上次压缩摘要且消息数增加, 只对**新增消息**生成增量摘要, 再与旧摘要合并, 避免对全量历史重复压缩。新增内容不足 50 字符时直接复用旧摘要。

5.3 双层压缩 (Dual-Layer)

`DualLayerCompressor` 提供两阶段防御纵深:

Original Context (100%)



Final Context

- L1 失败 $\Rightarrow$ 整体失败 (不可继续 L2);
- L1 结果已低于阈值 $\Rightarrow$ 跳过 L2;
- L2 失败 $\Rightarrow$ 回退 L1 结果 (优于无);
- 双层结果未通过安全验证 $\Rightarrow$ 降级激进截断。

6 协议转换层

代理同时兼容 OpenAI / Anthropic / Gemini 三种请求格式, 核心是 `ProviderAdapter` 抽象类与三个实现 (`OpenAIProvider` / `AnthropicProvider` / `GeminiProvider`)。

6.1 OpenAI → Anthropic 请求转换

当上游为 Anthropic 格式而客户端发送 OpenAI 请求时, `openai_to_anthropic_request` 执行字段映射:

OpenAI 字段	Anthropic 字段	说明
<code>role: system</code>	<code>system</code> 顶层	首个 <code>system</code> 消息提升为顶层
<code>role: assistant</code>	<code>role: assistant</code>	不变
<code>role: user</code>	<code>role: user</code>	不变
<code>content: "str"</code>	<code>content: [{type:text,...}]</code>	字符串转内容块
<code>tool_calls</code>	<code>tool_use</code> 块	函数调用转工具使用
<code>role: tool</code>	<code>tool_result</code> 块	工具结果消息转换

6.2 Anthropic → OpenAI 响应转换

`anthropic_to_openai_response` 将上游 Anthropic 响应还原为 OpenAI 格式, 使客户端无需感知上游差异: `content` 块提取文本、`thinking` 与 `tool_use` 分别映射为 OpenAI 的对应结构, 流式场景由 `convert_anthropic_sse_to_openai` 逐事件转换 SSE。

6.3 自动 Provider 探测

`detect_provider` 依据三路信号判定:

1. **模型名:** 含 `claude`/`Gemini` 特征词;
2. **请求头:**`anthropic-version` 头标记 Anthropic;
3. **上游 URL:**`anthropic/claude/coding-api` 子串判定 Anthropic 格式上游。


判定结果可通过 `COMPACTION_PROXY_UPSTREAM_IS_ANTHROPIC` (`auto/true/false`) 强制覆盖。

7 可靠性组件状态机

7.1 熔断器 (CircuitBreaker)

`CircuitBreaker` 三状态模型, 默认阈值 3 次失败、冷却 60 秒:

```
failure >= threshold
CLOSED -----> OPEN
  ^             |
  |             |
```



- **CLOSED**: 正常放行; 失败累计达阈值 → OPEN;
- **OPEN**: 拒绝压缩调用, 冷却期过后 → HALF_OPEN;
- **HALF_OPEN**: 试探放行一次, 成功 → CLOSED, 失败 → OPEN。

7.2 抖动检测 (ThrashingDetector)

ThrashingDetector 检测压缩蠕变 (Claude Code 同款思路): 在 W 条消息窗口内压缩次数达到 M (THRASHING_COMPACTS), 即判定蠕变并切换为**激进截断**而非 LLM 压缩, 避免”压缩 → 重填 → 再压缩”的死循环。

7.3 压缩缓存 (CompactionCache)

CompactionCache 以消息序列 SHA-256 为键缓存摘要, TTL 30 分钟。**缓存键同时纳入自定义压缩指令** (salt 参数), 确保不同指令不会串用缓存结果。

7.4 格式回退与重试

- Anthropic 上游返回仅 **thinking** 无文本时, 自动以流式重试捕获内容 (兼容部分模型非流式响应空文本的缺陷);
- 压缩调用带熔断与重试 (最多 MAX_COMPACTION_RETRIES 次, 每次递减保留轮次);
- 摘要为空或上游 4xx/5xx 时, 按提供商特定模式识别并降级。

8 会话存储架构

8.1 SessionStore(SQLite + FTS5)

SessionStore 提供跨会话持久化与全文检索:

```

-- 核心表(示意)
CREATE TABLE sessions (
  id          TEXT PRIMARY KEY,
  summary     TEXT NOT NULL,
  semantic    TEXT,
  msg_count   INTEGER,
  created_at  INTEGER,
  updated_at  INTEGER
);

```

```
CREATE VIRTUAL TABLE sessions_fts USING fts5(summary, semantic);
```

- `save_session`: 写入会话摘要、语义记忆快照与消息数;
- `search_sessions`: FTS5 全文搜索 (HTTP GET `/sessions/search`);
- `get_prior_summary` / `save_prior_summary`: 增量压缩的前置摘要状态;
- `save_transcript` / `get_transcript`: 原始转录存档, 支持会话恢复 (POST `/sessions/{id}/resume`)。

8.2 SemanticMemory(情节—语义双层记忆)

SemanticMemory 持久化为 JSON 文件 (原子写入):

- 六类知识槽位: `goals` / `decisions` / `errors` / `files` / `constraints` / `insights`;
- 每类上限 20 条 (去重 + 尾裁), 提示注入时取最近 10 条;
- 提取路径: LLM 结构化提取优先, 正则 (`commitments`) 兜底;
- 并发安全: 读写由 `threading.Lock` 保护, 落盘采用临时文件 + 原子替换。

8.3 UserProfile(用户画像)

UserProfile 将用户偏好持久化为 `USER.md` 格式 (Hermes 同款有界持久化), 供压缩提示注入, 保持跨会话的用户一致性。

9 配置说明

所有配置均通过环境变量提供, 默认值见下表。

9.1 核心配置

变量	默认值	说明
<code>COMPACTION_PROXY_PORT</code>	8198	代理监听端口
<code>COMPACTION_PROXY_UPSTREAM</code>	<code>http://localhost:11434/v1</code>	上游 LLM API 基地址
<code>COMPACTION_PROXY_UPSTREAM_IS_ANTHROPIC</code>	<code>auto</code>	强制 Anthropic 格式 (<code>true/f</code>)
<code>COMPACTION_PROXY_MODEL</code>	<code>gpt-4o-mini</code>	压缩/摘要模型

9.2 压缩行为

变量	默认值	说明
<code>COMPACTION_PROXY_KEEP_TURNS</code>	6	保留的最近轮次 (不压缩)

COMPACTION_PROXY_MAX_RETRIES	3	压缩 API 最大重试次数
COMPACTION_PROXY_TIMEOUT	120	压缩超时 (秒)
COMPACTION_PROXY_PARALLEL_BLOCKS	3	并行压缩块数
COMPACTION_PROXY_PREEMPTIVE_THRESHOLD	0.80	上下文 80% 时预压缩

9.3 双引擎压缩

变量	默认值	说明
COMPACTION_PROXY_ENGINE	default	压缩引擎 (default/dual-layer)
COMPACTION_PROXY_DUAL_GATEWAY_RATIO	0.15	L1 网关: 保留 15%(85% 缩减)
COMPACTION_PROXY_DUAL_AGENT_RATIO	0.50	L2 Agent: 保留 L1 输出的 50%

9.4 安全

变量	默认值	说明
COMPACTION_PROXY_API_SECRET	空	代理访问密钥; 为空时仅放行回环来源
COMPACTION_PROXY_REDACT_SECRETS	1	自动脱敏消息中的密钥

9.5 会话与记忆

变量	默认值	说明
COMPACTION_PROXY_BACKGROUND_SESSIONS	3	并行压缩的后台会话数
COMPACTION_PROXY_LLM_MEMORY	1	启用 LLM 记忆提取
COMPACTION_PROXY_MEMSKILL	0	启用自演进 MemSkill

10 接入指南

代理在 localhost:8198 监听, 兼容 OpenAI / Anthropic / Gemini 三种 API 格式。以下各节给出已实测试验的接入方式。

10.1 DeepSeek

DeepSeek 使用 OpenAI 兼容格式, 直接将其作为上游即可:

```
export COMPACTION_PROXY_UPSTREAM=https://api.deepseek.com/v1
export COMPACTION_PROXY_MODEL=deepseek-chat
python3 compaction-proxy.py
```

代理内置 DeepSeek 模型上下文窗口注册表 (deepseek-chat / deepseek-coder / deepseek-r1 / deepseek-v3, 均为 128K), 自动完成上下文压力预估。客户端侧只需将 base URL 指向代理:

```
export OPENAI_BASE_URL=http://localhost:8198/v1
export OPENAI_API_KEY=your-key
```

10.2 DeepSeek Harness

DeepSeek Harness(官方文档 <https://www.deepseek.com/harness/en/>) 是 DeepSeek 官方的 Agent 框架 (developer preview), 基于 Cordis 插件系统构建——模型、工具、技能、会话、沙箱、存储等一切能力均为可替换插件。其模型层支持 openai-completions(OpenAI 兼容) 与 Anthropic 两种协议, 可通过自定义 provider 将 baseURL 指向任意自托管端点。

本代理即以此方式接入。本机配置位于 \$DSH_HOME/settings.yaml (默认 7.dsh/settings.yaml):

```
# ~/.dsh/settings.yaml
llm-pi-ai:
  providers:
    xfyun-maas:
      displayName: 讯飞 MaaS via V6 Proxy
      apiKeyEnv: XF_MASS_API_KEY          # 凭证走环境变量引用, 不落盘
      api: openai-completions             # OpenAI 兼容协议
      baseURL: http://127.0.0.1:8198      # 指向压缩代理
      models:
        - id: xsparkx2agent
          name: xsparkx2agent
          contextWindow: 131072
          maxTokens: 8192
```

配置要点:

- baseURL 指向本代理 http://127.0.0.1:8198, 所有模型请求先经过代理的上下文监测与压缩层;
- api: openai-completions 与代理 /v1/chat/completions 端点匹配; 模型发现使用 OpenAI 兼容 GET /models;
- 凭证以环境变量引用 (apiKeyEnv), 密钥不写入配置文件;
- 模型变更即时生效, 无需重启 Harness 服务。

已验证: 本机 Harness 的 xfyun-maas provider 已指向 http://127.0.0.1:8198, 代理 /v1/chat/completions 端点路由正常。

10.3 Hermes Agent

Hermes Agent 在 7.hermes/config.yaml 的 model 段中配置模型端点。将其 base_url 指向本代理即可获得自动压缩能力:

```
# ~/.hermes/config.yaml
model:
  api_mode: chat_completions          # OpenAI 格式
  base_url: http://127.0.0.1:8198/v1  # 指向压缩代理
  default: xopglm51                   # 或任意上游可用模型
  provider: memory-proxy              # 保留原 provider 标识
```

代理的 `/v1/chat/completions` 端点与 Hermes 的 `chat_completions` 模式完全兼容 (已验证), 并支持 Anthropic 格式的 `/v1/messages` 端点。

10.4 Claude Code

Claude Code 原生使用 Anthropic Messages API。通过环境变量或 `7.claude/settings.json` 将 API 基地址指向代理:

```
# 方式一:环境变量
export ANTHROPIC_BASE_URL=http://localhost:8198
export ANTHROPIC_AUTH_TOKEN=<your-token>
claude
```

```
// 方式二:~/.claude/settings.json
{
  "env": {
    "ANTHROPIC_BASE_URL": "http://localhost:8198",
    "ANTHROPIC_MODEL": "claude-sonnet-5"
  }
}
```

已验证:POST `/v1/messages` 路由存在且 Anthropic 格式识别成功 (无密钥请求返回 401, 格式错误则返回 400/404, 可据此区分)。

10.5 OpenClaw

OpenClaw 通过 `openclaw.json` 的 `models.providers` 配置模型网关。将 provider 的 `baseUrl` 指向本代理即可让全部 Agent 流量经过压缩层:

```
{
  "models": {
    "providers": {
      "compaction-proxy": {
        "baseUrl": "http://127.0.0.1:8198",
        "apiKey": "<redacted>",
        "api": "openai-completions",
        "models": [{ "id": "xopdeepseekv4flash" }]
      }
    }
  }
}
```

```

},
"plugins": {
  "entries": {
    "v6-compaction-provider": {
      "enabled": true,
      "config": {
        "proxyUrl": "http://127.0.0.1:8198",
        "model": "xsparkx2agent"
      }
    }
  }
}
}
}

```

已验证: 本机 OpenClaw 的 xunfei provider 已直接指向 `http://127.0.0.1:8198`, 且 `v6-compaction-provider` 插件经 `/summarize` 端点接入压缩引擎 (即 OpenClaw 上下文压缩链路已全程经由本代理)。

11 原有上下文系统屏蔽

接入本代理后, 为避免多个压缩层互相冲突 (双重压缩、重复刷记忆), 应屏蔽各接入方自带的上下文管理系统, 使压缩完全由本代理统一接管。

11.1 屏蔽原则

- **单一压缩源:** 只有本代理执行上下文压缩, 接入方自身不再触发压缩;
- **手动压缩保留:** 部分接入方保留手动压缩命令 (如 `/compact`), 便于必要时人工触发;
- **可回滚:** 所有修改均保留原配置备份。

11.2 OpenClaw

修改 `openclaw.json` 中 `agents.defaults.compaction` 段:

```

"compaction": {
  "enabled": false,           // 关闭原版触发+替换+内置压缩
  "midTurnPrecheck": { "enabled": false },
  "memoryFlush": { "enabled": false },
  "qualityGuard": { "enabled": false },
  "provider": "v6-proxy"     // 保留 V6 插件作为压缩提供方
}

```

- 修改即时生效 (gateway 热重载, 无需重启);
- 自动压缩关闭后, 超长上下文完全交由本代理 (`127.0.0.1:8198`) 在 LLM 网关层处理;

- 手动 `/compact` 仍可用, 走 `v6-proxy` 压缩链路。

11.3 Hermes Agent

修改 `7.hermes/config.yaml`:

```
compression:
  enabled: false # 关闭 Hermes 自带自动压缩
```

- `compression.enabled: false` 会禁用 Hermes 全部自动压缩 (源码 `native_compaction.py` 明确注释);
- 手动 `/compress` 命令仍可触发压缩;
- 配置修改后需重启 Hermes 生效。

11.4 DeepSeek Harness

DeepSeek Harness 基于 Cordis 插件系统, 自带压缩后端插件 `dsh-compaction-basic` (Token 计量驱动, 默认 `auto: true` 注册步骤边界压力检测与溢出恢复监听)。通过 profile 的 `cordis.patch.yml` 将其关闭:

```
# ~/.dsh/profiles/web/cordis.patch.yml (headless 同理)
- id: dsh-compaction-basic
  config:
    auto: false # 关闭 Harness 原生自动压缩
```

- `auto: false` 后, Harness 不再自行在步骤边界压缩或做溢出恢复, 超长上下文完全交由本代理在 LLM 网关层处理;
- 手动压缩命令仍可用;
- 修改需重启 `dsh` 进程生效;
- 模型接入经 `$DSH_HOME/settings.yaml` 指向代理 (`baseUrl: http://127.0.0.1:8198`), 与屏蔽配置互不冲突。

11.5 Claude Code

修改 `7.claude/settings.json`:

```
{
  "autoCompactEnabled": false, // 关闭 Claude Code 自动压缩
  "autoCompactWindow": 110000
}
```

- `autoCompactEnabled: false` 后, Claude Code 不再自行压缩上下文;

- 压缩由指向的代理 (如 ANTHROPIC_BASE_URL) 接管;
- 手动压缩指令仍可用。

11.6 屏蔽效果验证

接入方	原系统	屏蔽后状态
OpenClaw	compaction 四项开关	全部 false, 代理接管
Hermes	compression.enabled	false, 代理接管
Claude Code	autoCompactEnabled	false, 代理接管

屏蔽完成后, 通过 GET /health 确认代理运行正常 (circuit_breaker.state = closed), 三方请求均经 8198 端口由本代理统一压缩。

12 安全与可靠性

12.1 认证

- 设置 COMPACTION_PROXY_API_SECRET 后, 所有敏感端点 (/summarize、/compact、/sessions/*、/skills/*、/profile、/memory、/arc/*) 要求 Authorization: Bearer <secret> 或 X-API-Key: <secret>;
- 未设置密钥时, 仅放行回环来源 (127.0.0.1 / ::1), 非回环客户端一律返回 401(纵深防御);
- 核心转发端点 (/chat/completions、/v1/messages) 保持无代理级认证, 依赖上游密钥校验, 以兼容本机 Agent 集成。

12.2 密钥保护

- Gemini API key 通过 x-goog-api-key 请求头传递, 不进入 URL 查询参数, 避免泄露至访问日志;
- 支持自动脱敏消息中的密钥 (COMPACTION_PROXY_REDACT_SECRETS=1)。

12.3 并发安全

- 压缩系统提示词以参数传递 (system_prompt_override), 不再修改模块级全局变量, 消除并发请求间的提示词竞态;
- SemanticMemory 读写由线程锁保护, 落盘采用原子替换;
- 压缩缓存按消息内容与自定义指令双重键控, 避免不同指令串用缓存;
- _memskill_selected 等内部字段在请求入口即被消费移除, 不会残留至上游请求体。

12.4 可靠性组件

- **熔断器**:3 次连续失败后进入 60 秒冷却;
- **抖动检测**: 连续快速压缩 (3 次/5 条消息) 时切换为激进截断;
- **压缩安全验证**: 压缩结果 token 数超过原文时降级为截断, 防止膨胀;
- **压缩缓存**:30 分钟 TTL, 避免对未变化上下文重复压缩。

13 验证结果

测试项	输入	结果
/health	GET	HTTP 200, 熔断器 closed
/summarize	2 条消息	HTTP 200,0.0s, 返回有效摘要
/summarize	12 轮 (24 条)	HTTP 200,13.1s,1948 字符, 保留轮次编号
并发压缩	6 路不同指令	全部 200, 无提示词串用
异常路径	缺 key / 坏 JSON / 空 体	401 / 400 / 200(符合预期)
/compact	16 条,keep=3	200,16 → 6 条
认证端点	本机回环	全部 200(回环放行)

14 常见问题

14.1 401 Unauthorized

- 检查代理自身密钥 (COMPACTION_PROXY_API_SECRET);
- Anthropic 格式使用 x-api-key 头,OpenAI 格式使用 Authorization: Bearer <key> 头。

14.2 上下文未压缩

- 检查 COMPACTION_PROXY_PREEMPTIVE_THRESHOLD(默认 0.80);
- 确认压缩模型在上游可用;
- 查看日志 7.local/share/compaction-proxy/proxy.log。

14.3 格式错误

- Anthropic 客户端: 使用 /v1/messages;
- OpenAI 兼容客户端: 使用 /v1/chat/completions;
- 代理自动探测格式, 但显式端点可避免歧义。

附：环境变量速查

完整配置模板见 `.env.example`。常用变量：

- `COMPACTION_PROXY_PORT`——监听端口 (默认 8198);
- `COMPACTION_PROXY_UPSTREAM`——上游 API 基地址;
- `COMPACTION_PROXY_MODEL`——压缩模型;
- `COMPACTION_PROXY_API_SECRET`——代理访问密钥;
- `COMPACTION_PROXY_ENGINE`——压缩引擎 (default / dual-layer);
- `COMPACTION_PROXY_MEMSKILL`——启用 MemSkill(0/1)。