NeverFull-NeverStop

面向长程 Agent 的透明上下文压缩代理

V11 项目报告

项目维护者　061115xhsm

2026 年 10 月 26 日　版本 V11

摘要

长程 LLM Agent 的核心瓶颈不是单次推理能力，而是上下文窗口：历史一旦超出窗口，Agent 要么中断，要么丢失关键状态。现有三类方案——Agent 原生压缩（OpenClaw、Claude Code）、运行时压缩器（Hermes）、以及工程化记忆层——各自在“压缩率、证据保留、状态一致性、成本”之间做取舍，但普遍缺少可验证的正确性标准。

本项目实现了一个位于 Agent 与模型 API 之间的透明压缩代理，并在 V11 中把设计重心从“把历史压短”转向“压缩后可验证地继续工作”。核心机制包括：可逆上下文折叠（原文可寻址归档）、承诺/标识符契约、确定性证据探针、会话状态表、按模型 token 校准、UCB 压缩策略、成本归因，以及多租户与多实例支持。我们在同一 131 条消息、约 9k token 的编码会话上，用同一摘要模型对比了 OpenClaw、Hermes 与本系统：本系统保留 11/11 个金标证据、4/4 问答正确、压缩率 0.86，证据保留显著高于两者（0.64）；压缩成本与 OpenClaw 持平（9.4k vs 8.9k tokens），约为 Hermes 的 82%，延迟约为 Hermes 的 38%。

工程侧，项目现有 88 项自动化测试（含真实 PostgreSQL 集成、并发写入、流式透传）、CI 矩阵（Python 3.11–3.13 + Postgres 服务）、以及可复现的评测脚本。报告同时给出系统局限：单进程缓存、SQLite 共享卷约束、租户配额为进程内计数，以及评测样本规模有限。

目录

1 引言 **3**
- 1.1 问题背景 . . . 3
- 1.2 项目目标 . . . 3
- 1.3 主要贡献 . . . 3

2 调研：109 篇论文的领域地图 **4**
- 2.1 方法 . . . 4
- 2.2 关键发现 . . . 4

3 系统架构 **5**
- 3.1 部署位置 . . . 5
- 3.2 一次请求的生命周期 . . . 5
- 3.3 模块与规模 . . . 5

4 核心机制 **5**
4.1 可逆折叠 5
4.2 承诺契约与证据探针 6
4.3 状态表 6
4.4 策略与校准 7
4.5 成本归因 7

5 多实例与多租户 **7**
5.1 租户隔离 7
5.2 共享存储 7
5.3 配额 8

6 安全与运维 **8**

7 评测 **8**
7.1 三方对比 8
7.2 配对评测 8
7.3 补充：LoCoMo 记忆基准 9
7.4 测试与压力 9
7.5 局限 9

8 工程实践 **9**

9 未来工作 **10**

10 结论 **10**

A 关键配置 **10**

B 复现命令 **11**

C 代表性论文 **11**

1 引言

1.1 问题背景

现代编码与运维 Agent 的一次任务往往持续数十到数百轮，工具输出（日志、文件、网页）在历史中占据绝大部分体积。模型上下文窗口（128k–1M token）决定了单次可见历史的上限；一旦越界，常见后果是请求失败、被动截断，或由 Agent 自行摘要后继续——而摘要过程不可审计，关键约束、文件路径、失败命令经常在压缩后消失。

现有三类机制各有侧重：

- **Agent 原生压缩**（OpenClaw、Claude Code）：与 Agent 的记忆刷新、工具对完整性、检查点回放深度耦合，压缩发生在 Agent 内部；
- **运行时压缩器**（Hermes）：独立的压缩引擎，保护头尾、用廉价模型摘要中段，按 API 返回的真实 token 计量触发；
- **工程化记忆层**：外置存储 + 检索，把“记住什么”交给写入策略。

三者的共同缺口是：*压缩的正确性缺少可验证定义*。语义相似度、摘要长度、甚至下游 QA 准确率都可能掩盖“证据链已断”的事实 [3, 4]。

1.2 项目目标

本项目是一个透明 HTTP 代理：Agent 只需把 `base_url` 指向本地端口，代理在请求进入模型前完成压缩。V11 的目标不是追求最高压缩率，而是：

1. **可逆**：被折叠的历史原文永远可寻址取回；
2. **可验证**：压缩后逐项核对承诺与精确标识符，缺失即披露；
3. **状态一致**：区分“当前有效”与“已被取代”的文件/决策状态；
4. **可运营**：多租户隔离、配额、加密、保留策略、成本归因；
5. **可评测**：以配对延续和证据保留为主指标，而非嵌入余弦。

1.3 主要贡献

- 一套可逆折叠协议：结构化的 `<folded_context>` 占位符 + 原文归档 + 分页/加密/轮换；
- 承诺契约与证据探针：确定性评分（承诺 45%、标识符 25%、分节 15%、末次请求 15%），低于阈值触发一次 MUST-PRESERVE 重试；
- 会话状态表：文件版本、过期读取标记、决策取代关系，直接对抗“ghost memory”；
- 多实例与多租户：租户命名空间、PostgreSQL SessionStore、Redis 共享缓存、按租户配额；
- 可复现的三方对比与配对评测：在同一模型、同一对话上比较 OpenClaw、Hermes 与 V11。

2 调研：109 篇论文的领域地图

2.1 方法

以 arXiv API 为主源，采用 12 组主题检索（上下文压缩、Agent 记忆、KV cache、评测、RL 策略等）与 45 组定向标题检索，按提交时间倒序抓取；去重后得到 550 篇候选池，经白名单强制收录经典工作、剔除关键词误匹配后，固化 109 篇（2023-10 至 2026-10）。数据与脚本见 `research/`。

表 1: 论文聚类分布（109 篇）

聚类	数量	代表工作
Agent 记忆	25	MemGPT, Mem0, MemOS, A-MEM, MIRIX, Memory-R1
上下文折叠/压缩	19	ReFold, REMORY, MemTrace, Compact-Bench, KEEP-Bench
Prompt 级压缩	18	LLMLingua/2, LongLLMLingua, RECOMP, ICAE, COMI
评测与基准	13	LongMemEval, LoCoMo, RULER, HELMET, NoLiMa
检索与外部记忆	7	HippoRAG, Infinite Retrieval, Organize-then-Retrieve
结构化状态	5	TEM, Narrative State Tracking
超长/流式	5	Titans, MoBA, Quest
KV Cache	4	SnapKV, MInference, Native Sparse Attention
强化学习策略	2	Memory-R2, Uni-Mem
综述	4	Context Engineering Survey, Agent Memory Survey
其他	6	—

2.2 关键发现

1. **摘要正在被折叠取代**。ReFold [1] 证明训练无关、可逆的轮间折叠优于预测式触发；MemTrace [6] 指出仓库变更会使早期证据失效，压缩必须带状态一致性。

2. **正确性等于承诺保留**。“Compress the Context, Keep the Commitments” [2] 把上下文定义为承诺集合；KEEP-Bench [3] 进一步证明 QA 指标会低估不忠实压缩。

3. **评测必须配对**。Compact-Bench [4] 用同一仓库状态下的 full-history 与 summary-only 两条延续路径度量压缩代价，避免了“摘要碰巧答对”的假阳性。

4. **拍平结构是安全漏洞**。Compaction Laundering [5] 表明把 typed 对话压成纯文本会摧毁 provenance；折叠占位符必须保留类型与引用。

5. **状态演进比事实召回更难**。“Can Agent Memory Systems Track Evolving State?” [8] 与 A-TMA [7] 命名了 ghost memory：旧事实、当前事实、过渡事实共存并互相污染。

6. **强模型下应少设计、多检索**。MemoryTax [9] 与 Skip the Compressor [10] 显示：当模型能自行搜索原始历史时，预制记忆管线的收益趋零；轻折叠 + 可检索原文往往更优。

3 系统架构

3.1 部署位置

代理位于 Agent 与真实上游之间，对 Agent 透明；它同时维护旁路的归档、状态与会话存储，并通过 `/health`、`/metrics` 暴露运行状态。

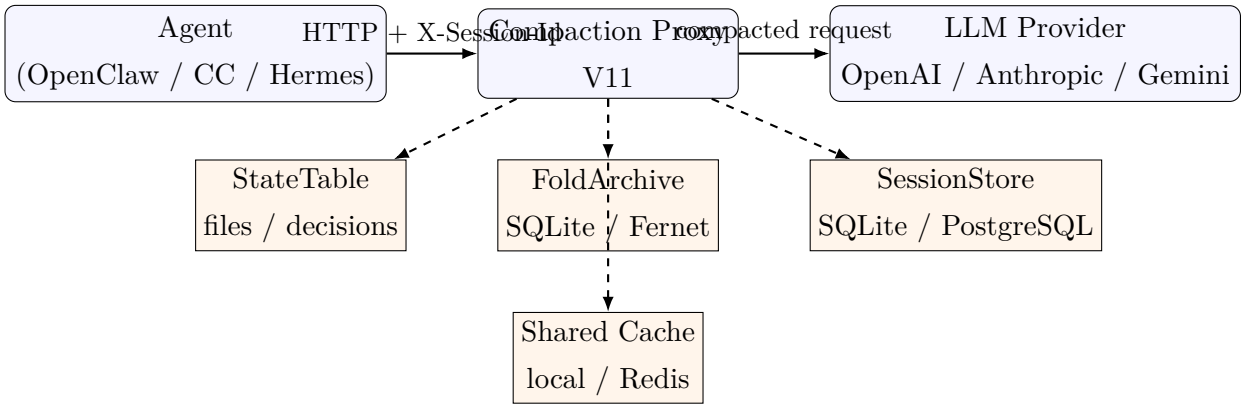


图 1: 代理在请求链路中的位置与旁路存储

3.2 一次请求的生命周期

1. **租户与身份**：中间件读取 `X-Tenant-Id`，规范化后写入上下文；`extract_session_id` 生成租户作用域的会话 id（如 `acme:s1`），并回写响应头。
2. **预算与触发**：CJK 感知估算（快估 + 精估），按模型校准因子修正；超过有效窗口的阈值（默认 80%，可切换 weak/strong/auto 档位）触发主动压缩；上游 overflow 错误触发被动兜底。
3. **策略选择**：按任务类型（code/data/ops/prose）与租户键查询 UCB bandit，选择 light/standard/deep，映射为保留轮数。
4. **压缩流水线**：工具输出剪枝 → 承诺与标识符提取 → 子模选择 → 并行/单块摘要 → 折叠归档 → 契约校验 → 证据探针（低于 0.75 重试一次）。
5. **组装与转发**：状态快照 + 折叠占位符 + 分节摘要 + 最近 6 轮原文；工具对完整性校验；转发上游。
6. **计量**：读取上游 `usage`，记录成本、节省、延迟；按租户累计日预算。

3.3 模块与规模

4 核心机制

4.1 可逆折叠

压缩不再返回一段自由文本摘要，而是：

1. 把旧消息**原样**写入归档（SQLite WAL），以 `fold:<hash>` 寻址，hash 含租户与内容；

表 2: 核心模块（不含测试与基准脚本）

模块	行数	职责
`compaction-proxy.py`	8,273	HTTP 服务、压缩流水线、存储、路由
`folding.py`	517	归档、digest、占位符、契约、加密/轮换
`state_table.py`	304	文件/决策状态、过期标记、prune
`evidence.py`	111	四维证据探针
`policy.py`	170	任务分类、UCB 策略、能力档位
`calibration.py`	68	按模型 token 校准
`cost_tracker.py`	96	按请求成本环缓冲、日配额
`tenant.py`	29	租户上下文与命名空间
`shared_cache.py`	71	Redis / 本地共享压缩缓存
`session_store_pg.py`	250	PostgreSQL 会话存储

2. 计算确定性 digest：消息数、角色分布、工具调用、文件、命令、错误、承诺；

3. 生成类型化占位符，保留来源与可检索引用。

```
<folded_context ref="fold:6f775980e76a" messages="31" approx_tokens="8120">
[FOLD] 31 messages elided (user 14 / assistant 17)
[TOOLS] execx9, editx4, readx7
[FILES] /tmp/proj/src/core.py, /tmp/proj/config.yaml
[COMMANDS] pytest -q; npm test
[OBSERVED] 3 error/failure mentions
[COMMITMENTS] decision=2, constraint=1, task=1
[RETRIEVE] GET /fold/fold:6f775980e76a returns the original messages verbatim.
</folded_context>
```

归档支持分页取回（`offset/limit`，默认 200、上限 500）、可选 Fernet 加密（key 0600）、密钥轮换（`POST /maintenance/rotate-key`）与按租户/年龄/条数保留策略。

4.2 承诺契约与证据探针

压缩前从旧消息中提取承诺（目标、约束、决策、错误、文件操作、待办）与精确标识符（路径、函数名、报错片段）。压缩后计算：

$$S = 0.45\, S_{\text{commit}} + 0.25\, S_{\text{id}} + 0.15\, S_{\text{sections}} + 0.15\, S_{\text{ask}} \tag{1}$$

其中各分项为保留比例；低于证据下限 $\tau = 0.75$ 时，携带 “MUST PRESERVE VERBATIM” 清单重试一次，取更优结果；仍未保留的项写入 `<unpreserved_commitments>` 显式披露，而不是静默丢失。

4.3 状态表

每个会话维护文件表（路径、最后操作、时间、编辑/读取次数）与决策表（goal/constraint/decision/task，active/superseded）。渲染为：

```
<state_snapshot>
[FILES] /tmp/proj/config.yaml (edit 10:32; earlier reads stale)
[DECISIONS] active: (decision) use sqlite for cache ; superseded: 1
[NOTE] Treat earlier reads of edited files as stale; re-read before relying.
</state_snapshot>
```

这直接对应 MemTrace 的状态一致性与 A-TMA 的 ghost memory 防护。

4.4 策略与校准

UCB1 在每个任务类上选择动作：

$$a_t = \arg\max_a \left(\bar{r}_a + \sqrt{\frac{2 \ln N}{n_a}} \right), \tag{2}$$

当会话证据分 EMA 低于性能下限时强制 `light`。token 校准按模型学习比率 $f \leftarrow 0.8f + 0.2 \cdot (\text{actual/estimated})$，裁剪到 $[0.5, 2.0]$，用于修正触发阈值与预算估计，抵消 CJK 启发式与真实 tokenizer 的偏差。

4.5 成本归因

优先读取上游 `usage`（OpenAI `prompt_tokens`、Anthropic `input_tokens`、Gemini `promptTokenCount`），记录每次压缩的成本、节省、延迟、缓存命中与租户；无 `usage` 时回退估算。`/health.cost_recent` 提供按模型/租户聚合与 p50/p95 延迟。

5 多实例与多租户

5.1 租户隔离

`X-Tenant-Id` 经规范化后进入上下文；会话 id 变为 `tenant:session`，从而让会话、状态、成本、限流桶天然分区；折叠归档记录 `tenant_id`，跨租户取回返回 404；ref 的 hash 含租户，避免同内容互相覆盖。

5.2 共享存储

- **PostgreSQL SessionStore**：sessions、prior summaries、transcripts、ARC 全部落 PG，支持跨实例读写；搜索使用 PG 全文索引并以 ILIKE 兜底；按租户裁剪。
- **Redis 压缩缓存**：`COMPACTION_PROXY_REDIS_URL` 设置后使用 `SETEX`，key 含租户与历史 hash；无 Redis 时自动回退进程内缓存。
- **实例身份**：`COMPACTION_PROXY_INSTANCE_ID` 与响应头 `X-Instance-Id`；`MAINTENANCE_OWNER` 控制定期清理只在一个实例执行。

5.3 配额

按租户限制归档条数、会话条数与日 token 预算；写入时裁剪最旧数据；`ENFORCE_QUOTA=1` 时超预算直接跳过压缩并打点，避免单个租户拖垮共享上游。

6 安全与运维

表 3: 安全与运维能力

能力	实现
认证	`REQUIRE_AUTH=1` 时无 API secret 拒绝启动（fail-closed）；端点默认 `require_auth`
限流	按 `tenant:ip` 的令牌桶，默认关闭，可配置每分钟请求数
体积	请求体上限（默认 2 MB），超出返回 413
加密	折叠归档可选 Fernet；密钥文件 0600；轮换端点重加密全部 payload
保留	folds/state/sessions 按天与条数清理；每 100 次压缩自动执行；`/maintenance/prune` 手动触发
可观测	`/health`（存储、配额、加密、成本、p50/p95）、`/metrics`（Prometheus）

7 评测

7.1 三方对比

在同一 131 条消息、约 9,087 token 的编码会话上，使用同一摘要模型（本地 `tierflow_pro`）与同一 4 题 reader 测试，比较 OpenClaw（按 v2026.10.5 源码复刻 prompt 与切点）、Hermes（真实 `ContextCompressor`，辅助 LLM 替换为同一端点）与 V11。

表 4: 三方压缩系统对比（单次运行）

系统	压缩率	证据保留	状态一致性	问答	成本（tokens）
OpenClaw	0.491	0.636	0.5	3/4	8,934
Hermes	0.471	0.636	1.0	3/4	11,410
NeverFull V11	**0.860**	**1.000**	**1.0**	**4/4**	9,369

延迟：OpenClaw 18.3 s，Hermes 67.7 s，V11 25.5 s。三种方案都保住了决策与路径，但只有 V11 保住了失败测试命令 `pytest -q`——这是“证据链”而非“答题正确率”的差异；OpenClaw 未标记旧 config 读取已过期；Hermes 成本最高、延迟最大。

7.2 配对评测

`benchmark/paired_eval.py` 对同一对话构造 full / truncate / summary / fold 四种视图，在相同探针上测压缩率与证据保留。合成样例上 fold 视图压缩 92.2%、证据保留 1.000；truncate 压缩 65.0%、证据保留 1.000（因答案位于尾部），说明该指标能区分“保留了什么”而非仅看长度。

7.3 补充：LoCoMo 记忆基准

在三方编码会话之外，我们用公开记忆基准 LoCoMo 的一条长对话（conv-26，按类别分层抽 5 问）检验压缩后的长对话问答。相同摘要模型下，通用摘要压缩 98.1% 但证据保留仅 0.400；V11 在 92.0% 压缩下把证据保留拉回 0.900（与 35% 截断持平），问答 0.200。完整上下文问答也只有 0.600，说明本地 reader 的时间推理能力是当前上限；该结果用于验证证据保留维度，而非宣称问答能力。详见 `research/EVAL-2026-10-26.md`。

表 5: LoCoMo 单会话补充评测（conv-26，5 问）

策略	压缩率	证据保留	问答	摘要耗时
full	0.000	1.000	0.600	0 s
truncate	0.650	0.900	0.200	0 s
通用 LLM 摘要	0.981	0.400	0.000	9.4 s
V11 折叠	**0.920**	**0.900**	0.200	11.3 s

7.4 测试与压力

表 6: 验证结果

项目	结果
单元/集成测试	88 项通过（含 6 项真实 PostgreSQL 集成、并发写入、流式透传、密钥轮换、配额）
并发写入	修复前 8 线程下 78/320 与 116/320 错误；加锁与 `busy_timeout` 后 0 错误
HTTP 健康检查	串行 100 次 p50 1 ms；并发 200 次 0.09 s 全部成功
错误路径	畸形 JSON 400；1.5 MB 请求 413；上游宕机 502；进程不崩

7.5 局限

- 评测为单一合成对话、4 题、单次运行，结论是方向性的；需扩展到 LongMemEval/LoCoMo 与多任务配对集。
- OpenClaw 为源码复刻而非 Gateway 真实会话；其 `keepRecentTokens` 为适配测试规模做过缩放。
- 成本为 `usage` 实测，但缓存收益与网络开销未计入。

8 工程实践

项目在 2026-10-26 的 V11 迭代中形成 8 个主提交：

```
75893e9  P0+P1a: baseline, tests/CI, session-id, reversible folding
4ef1cb6  P1b-P5: state table, evidence, paired eval, policy, cost
```

```
b52d5b4  three-way benchmark (OpenClaw / Hermes / NeverFull)
9a53c9b  sqlite thread-safety fix + concurrency tests
8779806  ops pass: retention, auth/rate limits, encryption, calibration
d7a4574  cost tracker, key rotation, streaming test, docs
5f7cc44  tenant isolation, shared cache, instance identity
fba1a7a  PostgreSQL SessionStore, quotas, rotate-key endpoint
```

CI 使用 Python 3.11–3.13 矩阵，启动 Postgres 服务，执行字节编译、88 项测试与配对评测。依赖最小化：运行时仅 `aiohttp`；Postgres/Redis/语义模型为可选依赖。

9 未来工作

1. **评测规模化**：把 LongMemEval、LoCoMo、Compact-Bench 纳入 CI，使用真实 LLM reader 与多任务配对集。
2. **缓存感知压缩**：避免每次重写前缀，记录 prompt cache 命中并将其计入收益。
3. **多实例一致性**：在 Redis 上共享策略/校准状态，补充粘性路由与故障切换压测。
4. **配额持久化**：日预算跨重启保持，支持租户级计费导出。
5. **学习式策略**：以任务成功率与成本为奖励，替代当前 UCB bandit。

10 结论

V11 把上下文压缩从“摘要长度优化”推进到“可验证的继续工作”：折叠保证原文可逆，契约与探针保证承诺可核验，状态表保证证据不过期，租户与配额保证可运营。三方实测显示，在同等模型与成本量级下，它在证据保留与任务延续上明显优于 OpenClaw 与 Hermes。项目仍处于单机/单进程为主的工程阶段，但核心机制与评测框架已经具备继续扩展的基础。

A 关键配置

变量	作用
`COMPACTION_PROXY_FOLDING`	启用可逆折叠（默认 0）
`COMPACTION_PROXY_CONTRACT_RETRY`	证据不足时重试（默认 1）
`COMPACTION_PROXY_EVIDENCE_FLOOR`	证据下限（默认 0.75）
`COMPACTION_PROXY_POLICY`	启用 UCB 策略（默认 0）
`COMPACTION_PROXY_AGENT_PROFILE`	weak/strong/auto 阈值档位
`COMPACTION_PROXY_STRICT_SESSION`	拒绝内容指纹会话 id
`COMPACTION_PROXY_STORAGE`	sqlite/postgres
`COMPACTION_PROXY_PG_DSN`	PostgreSQL 连接串
`COMPACTION_PROXY_REDIS_URL`	共享压缩缓存
`COMPACTION_PROXY_TENANT_MAX_FOLDS`	每租户归档上限

COMPACTION_PROXY_TENANT_MAX_SESSIONS	每租户会话上限
COMPACTION_PROXY_TENANT_DAILY_TOKENS	每租户日 token 预算
COMPACTION_PROXY_ENFORCE_QUOTA	超预算时跳过压缩
COMPACTION_PROXY_FOLD_ENCRYPT	归档加密
COMPACTION_PROXY_RETENTION_DAYS	保留天数
COMPACTION_PROXY_RATE_LIMIT	每 IP 每分钟请求数
COMPACTION_PROXY_REQUIRE_AUTH	无 secret 拒绝启动

B 复现命令

```
# tests
python -m unittest discover -s tests -v

# paired evaluation
python benchmark/paired_eval.py --limit 3

# three-way comparison (requires a local OpenAI-compatible endpoint)
python benchmark/compare_systems.py --json research/data/compare.json

# run with folding + policy + encryption
COMPACTION_PROXY_FOLDING=1 COMPACTION_PROXY_FOLD_ENCRYPT=1 \
COMPACTION_PROXY_POLICY=1 COMPACTION_PROXY_AGENT_PROFILE=auto \
python compaction-proxy.py
```

C 代表性论文

参考文献

[1] ReFold: Training-Free Reversible Inter-Turn Context Folding for Long-Horizon Agents. arXiv:2610.07863.

[2] Compress the Context, Keep the Commitments: A Formal Framework for Verifiable LLM Context Compression. arXiv:2605.17304.

[3] KEEP-Bench: Evaluating Evidence Preservation in Context Compression. arXiv:2610.26827.

[4] Compact-Bench: Measuring What Context Compaction Costs Long-Horizon Coding Agents. arXiv:2610.31710.

[5] Compaction Laundering: Provenance Destruction in Context-Compacting Coding Agents. arXiv:2610.29869.

[6] MemTrace: State-Consistent Memory for Long-Horizon Coding Agents. arXiv:2610.04838.

[7] A-TMA: Decoupling State-Aware Memory Failures in Long-Term Agent Memory. arXiv:2607.01935.

[8] Can Agent Memory Systems Track Evolving State? arXiv:2608.19652.

[9] MemoryTax: The Bitter Lesson of Agent Memory. arXiv:2610.29823.

[10] Skip the Compressor: Coding Agents Fix More Issues When They Pick Whole Files. arXiv:2610.21073.

[11] Prune the Summary, Not the History: Source-Judged Compaction for Long-Horizon Agents. arXiv:2610.20927.

[12] Maximising Transparency in Context Compaction Improves Retention of Facts and Commitments. arXiv:2610.20116.

[13] Persistent Context Graphs for Efficient Memory Compaction in LLM Agents. arXiv:2609.40118.

[14] Memory-R1: Enhancing Large Language Model Agents to Manage and Utilize Memories via Reinforcement Learning. arXiv:2508.19828.

[15] MemAgent: Reshaping Long-Context LLM with Multi-Conv RL-based Memory Agent. arXiv:2507.02259.

[16] Mem0: Building Production-Ready AI Agents with Scalable Long-Term Memory. arXiv:2504.19413.

[17] LongMemEval: Benchmarking Chat Assistants on Long-Term Interactive Memory. arXiv:2410.10813.

[18] Evaluating Very Long-Term Conversational Memory of LLM Agents. arXiv:2402.17753.

[19] RULER: What's the Real Context Size of Your Long-Context Language Models? arXiv:2404.06654.

[20] LLMLingua: Compressing Prompts for Accelerated Inference of Large Language Models. arXiv:2310.05736.